Infrastructure Big Data

Projet d'examen — Deux analyses de données

LAWSON Arnel

Code source disponible sur GitHub :

https://github.com/Arnel7/projet-Infrastructure-Big-data

Sommaire

1. Projet 1 : Enquête de marché
2. Projet 2 : Analyse Big Data retail
3. Conclusion

Projet 1 — Contexte et données

Contexte

Une entreprise souhaite lancer une activité de vente de plats jetables. Une enquête terrain a été réalisée pour comprendre les attentes des clients.

Données

- Fichier : `enquête.xlsx`
- **123 répondants**
- **29 variables**

Outils utilisés

- Python 3.12
- pandas, matplotlib
- seaborn, numpy

Projet 1 — Préparation des données

- Renommage des 29 colonnes en noms courts
- Suppression de la colonne `photo_url` (non pertinente)
- Conversion des montants textuels en numériques
  - `"10.000f"` → `10000.0`
  - `"5000 à 10000f"` → `7500.0` (milieu de plage)
  - `"20 ou 35 milles"` → `27500.0`
- Remplacement des NaN numériques par la **médiane**
- Harmonisation : fréquences, quantités, intention d'achat
- Résultat : **0 valeur manquante**, **28 colonnes**

Projet 1 — Analyse exploratoire

Activités des répondants

- Majoritairement restaurateurs
- Mets africains et européens
- Fast-foods et snacks

Utilisation actuelle

- **100%** utilisent des emballages jetables
- 48% : 1–10 unités/jour
- 38% : 10–30 unités/jour
- 14% : 30–50 unités/jour

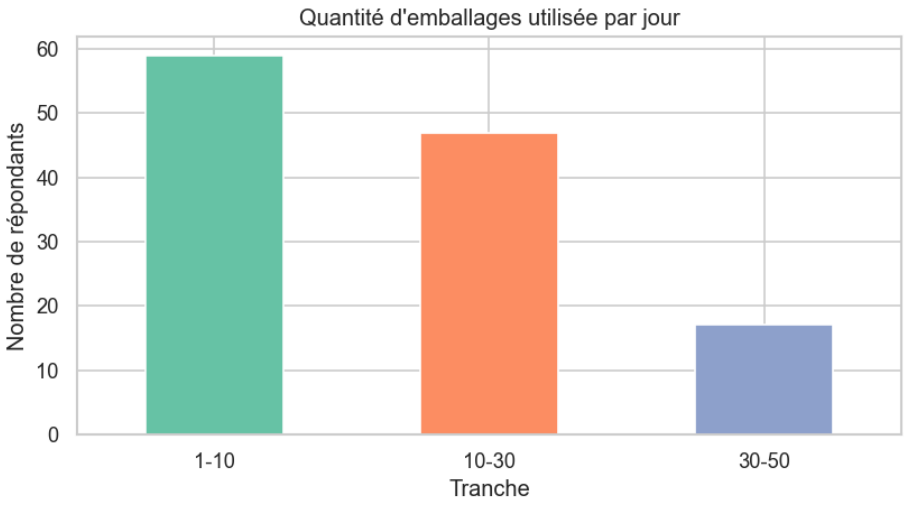

Projet 1 — Préférences des clients

- **Compartiments** : combinaisons 1–3 compartiments les plus demandées
- **Contenance** : 850 ML préférée (1 compartiment)
- **Design** : 78.9% veulent une fenêtre transparente
- **Matériau** : Carton et Bioplastiques en tête

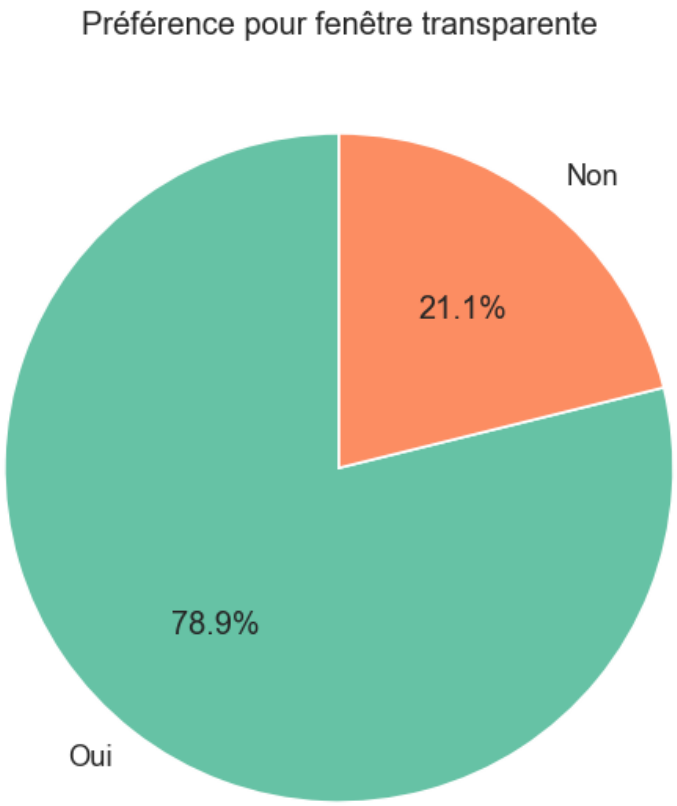

Projet 1 — Sensibilité au prix

Chiffres clés

- Prix médian actuel : **3 500 FCFA/centaine**
- Budget mensuel médian : **7 000 FCFA**
- 36.6% prêts à payer plus cher
- 58.5% répondent "peut-être"

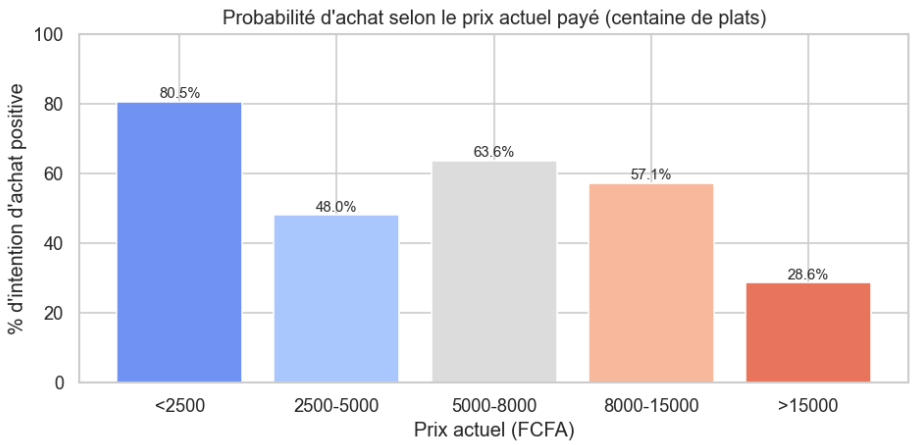

Projet 1 — Intention d'achat

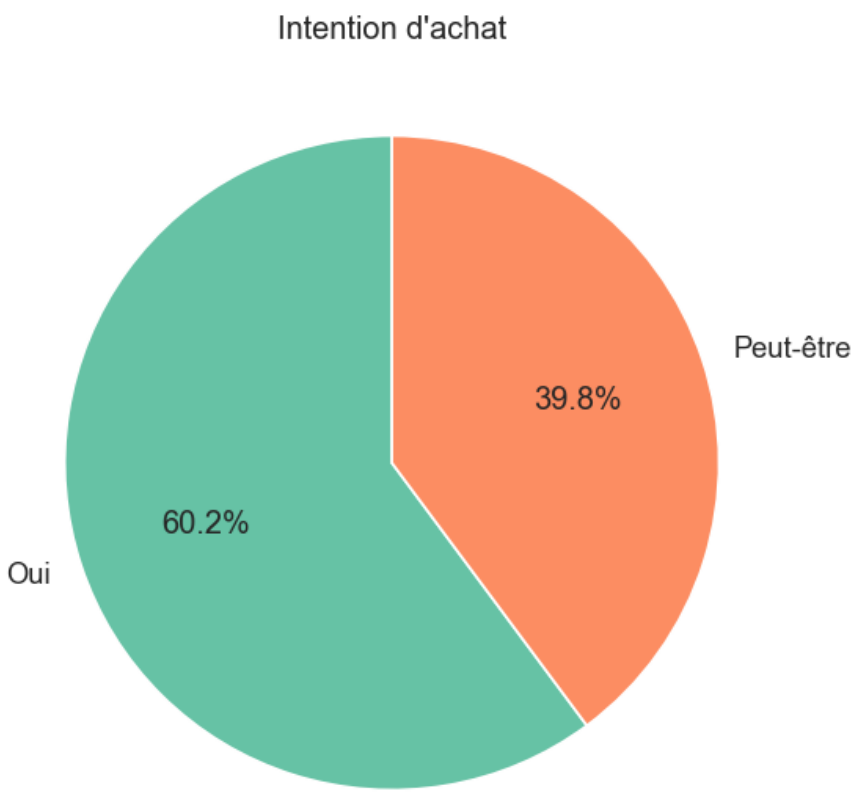

- **60.2%** ont une intention d'achat positive
- Livraison **hebdomadaire** préférée
- **Distribution locale** plébiscitée

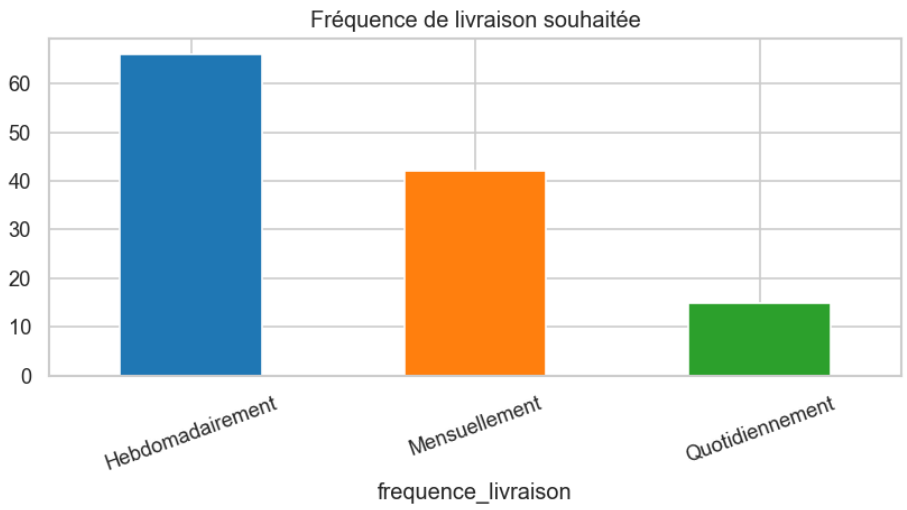

Projet 1 — Segmentation des clients

Méthode : règles métier

- Score basé sur quantité, budget et disposition à payer plus

Segment	Nb	Budget moy.
B - Moyen	54	11 889 FCFA
C - Petit	69	5 152 FCFA

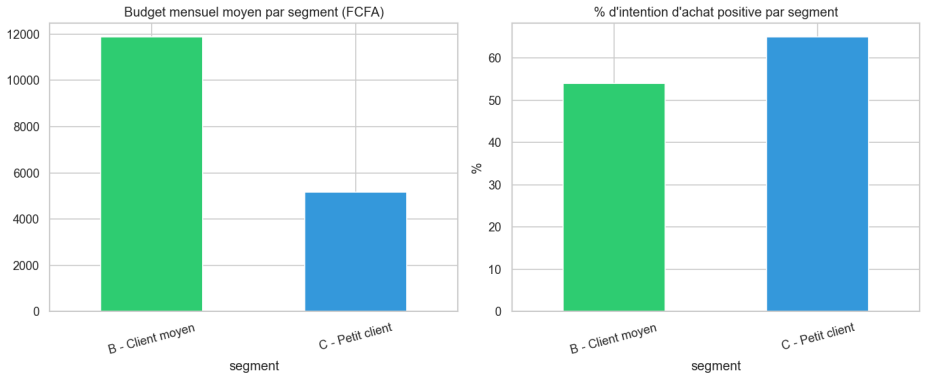

Projet 1 — Recommandations

Produit

- Multi-compartiments (1–3), carton ou bioplastique, avec fenêtre
- Contenance cible : 850 ML (1 comp.), 800 ML (2 comp.)

Politique de prix

- Positionner entre **3 000 et 4 000 FCFA** la centaine
- Offrir une gamme premium pour les 36.6% prêts à payer plus

Approvisionnement

- Priorité à la **distribution locale**
- Cadence de livraison **hebdomadaire**

Projet 2 — Contexte et données

Contexte

Analyse de données de ventes en commerce de détail avec **Apache Spark (PySpark)**. Traitement sur serveur distant Ubuntu 31 GB RAM.

Données

- Fichier : `retailsale.csv`
- **109 443 lignes**
- **10 colonnes**
- 311 produits, 107 magasins

Outils

- PySpark 4.1.1
- Spark MLlib
- Python 3.13 (serveur)
- matplotlib, seaborn

Projet 2 — Prétraitement avec Spark

- Chargement CSV avec inférence de schéma automatique
- Suppression de `promo_type_2` (sans variabilité analytique)
- Remplacement des NaN de `promo_bin_1` (89%) par `"Aucune"`
- Suppression de la ligne avec NaN dans price, stock, sales
- Conversion `date` → `DateType`
- Recast : sales (int), stock (int), price (float)
- Nouvelles variables créées :
  - `revenu_calcule` = sales × price
  - `annee`, `mois`, `semaine`
  - `en_promotion` : binaire basé sur `promo_bin_1`
- Résultat : **109 442 lignes**, **0 NaN**

Projet 2 — Statistiques descriptives

Variable	Moyenne	Std	Min	Max
sales	0.46	2.22	0	161
revenu_calcule	1.57	7.39	0	796.95
stock	16.01	40.79	0	2 892
price	8.92	10.87	0.25	219.90

Observation clé

La médiane des ventes est **0** : la majorité des combinaisons produit-magasin-date n'enregistrent aucune vente. Ce phénomène est typique des données retail à grande dimension.

Projet 2 — Top produits et magasins

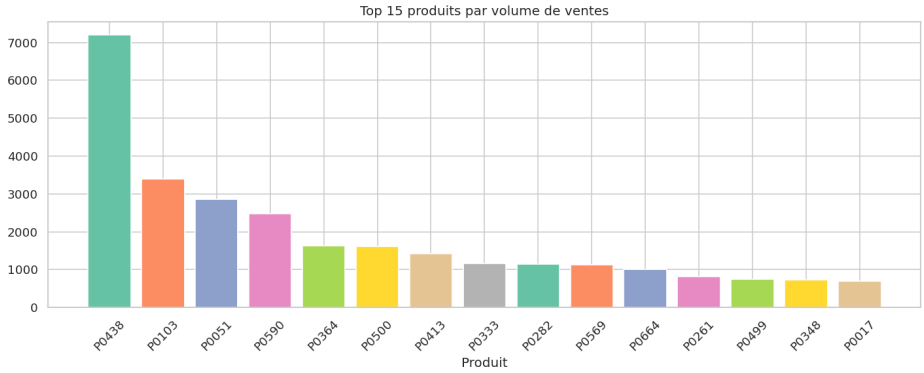

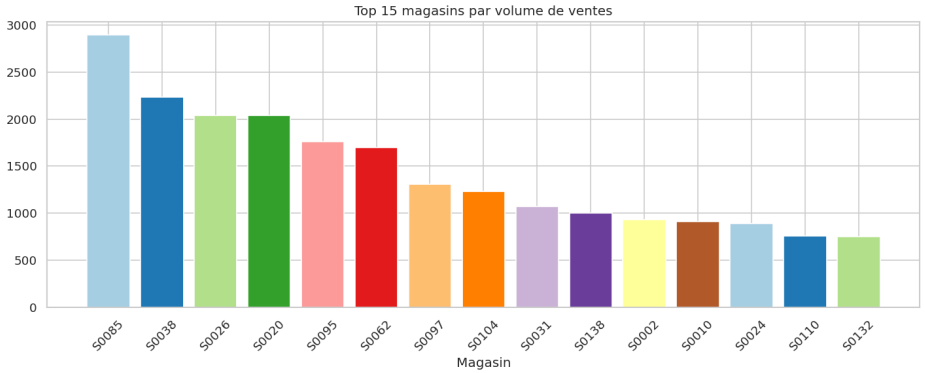

- **P0438** est le produit le plus vendu (7 194 unités)
- **S0085** est le magasin le plus performant (2 893 unités)

Projet 2 — Évolution temporelle

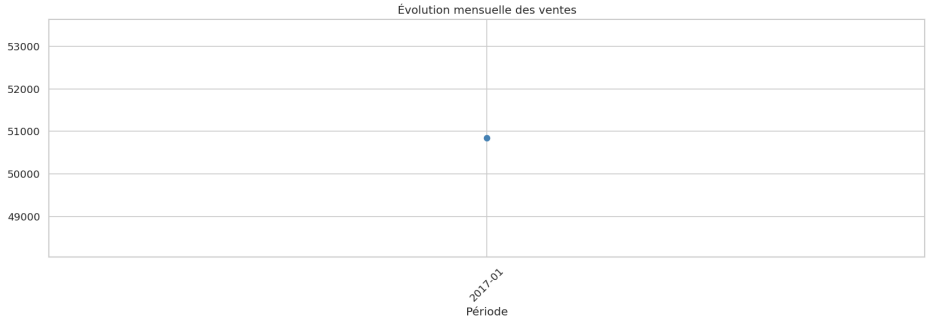

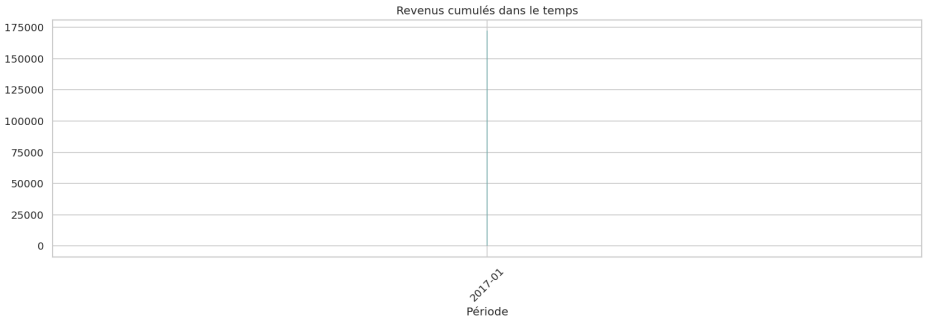

Les revenus cumulés croissent régulièrement sur la période analysée, confirmant une activité commerciale stable.

Projet 2 — Impact des promotions et prix

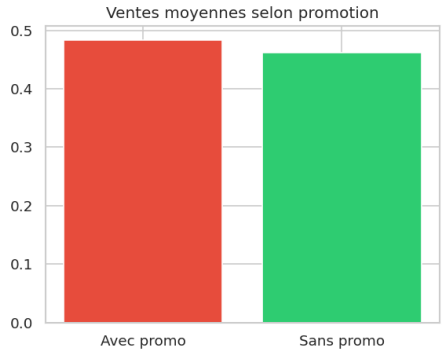

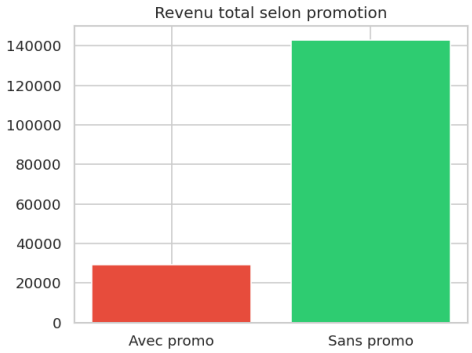

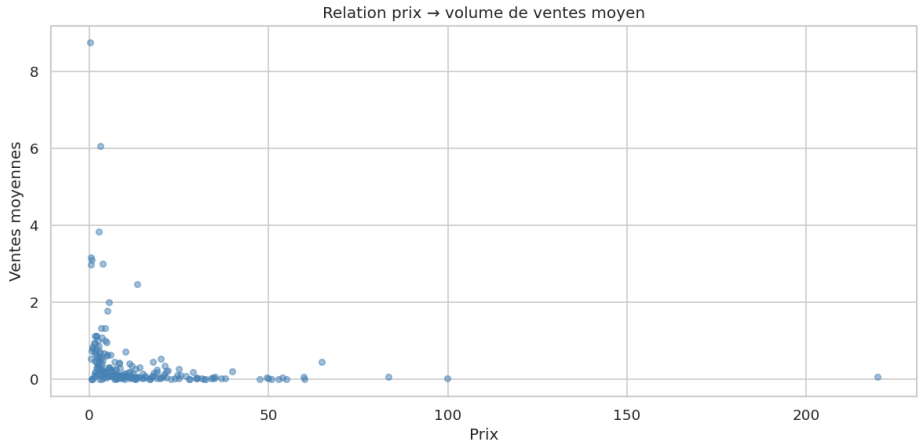

- Les articles en promotion ont des ventes légèrement supérieures (+4.8%)
- La relation prix-ventes montre une tendance négative modérée

Projet 2 — Corrélations

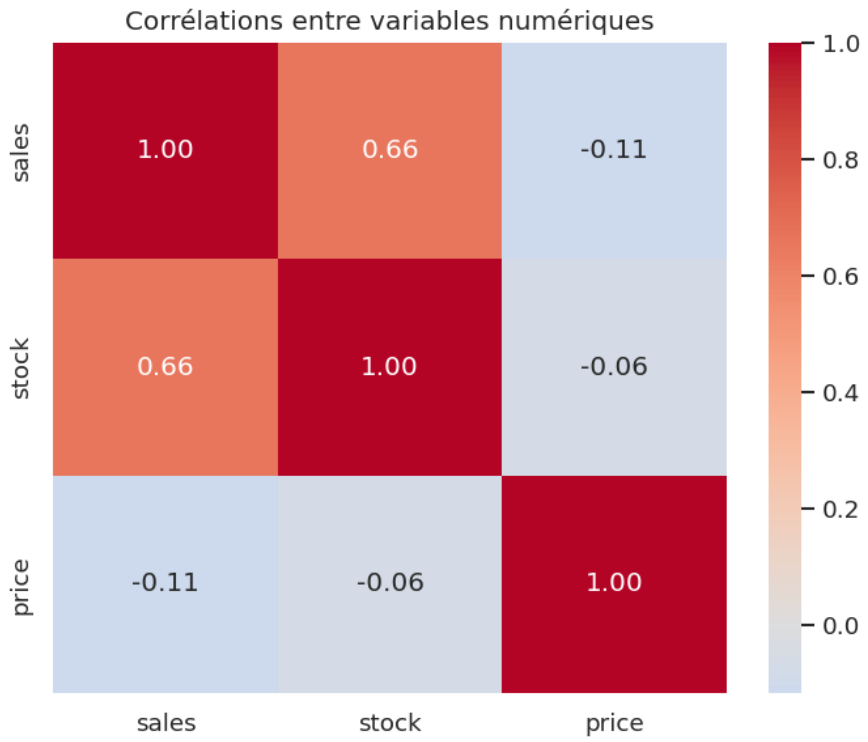

Paire	Corr.
sales ↔ stock	**+0.45**
sales ↔ price	-0.11
price ↔ stock	-0.11
sales ↔ promo	+0.00

Le stock est la variable la plus corrélée aux ventes.

Projet 2 — Modélisation (Spark MLlib)

Modèle : Régression Linéaire

Variables explicatives : `price`, `stock`, `en_promotion`
Variable cible : `sales`

Métrique	Valeur
RMSE	1.8564
MAE	0.6802
R^2	0.1872

Le R^2 de 0.19 indique que d'autres facteurs (saisonnalité, localisation) influencent également les ventes.

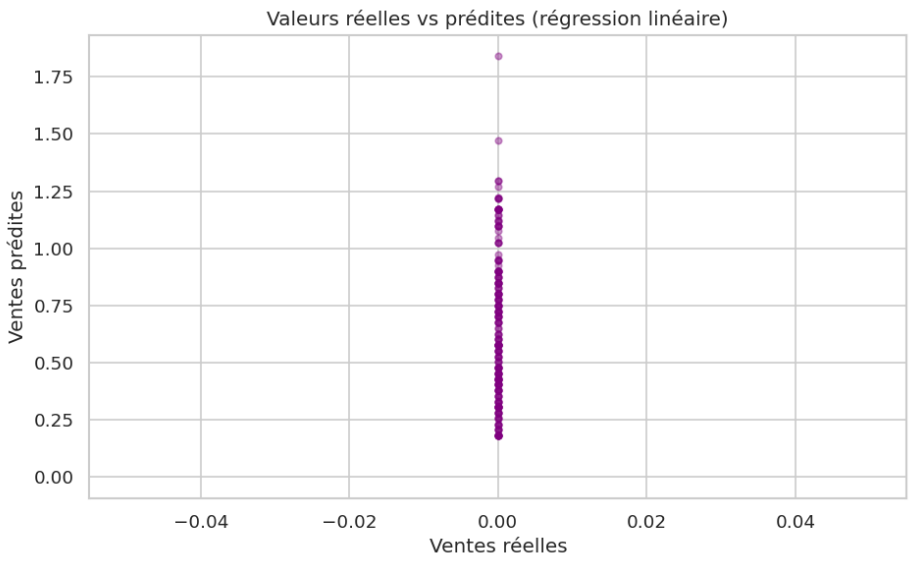

Projet 2 — Recommandations

Gestion des stocks

- Maintenir un stock suffisant pour P0438, P0103, P0051
- Réapprovisionner les produits à 0 vente seulement lors de promotions

Stratégie de promotion

- Cibler les promotions sur les produits à fort potentiel
- Planifier en période de faible activité saisonnière

Politique de prix

- Produits d'entrée de gamme (bas prix) pour maximiser le volume
- Produits premium pour maximiser le revenu unitaire

Conclusion

Projet 1

- 123 répondants analysés
- Données nettoyées à 0 NaN
- 20 visualisations produites
- 2 segments identifiés
- Recommandations produit, prix et approvisionnement

Projet 2

- 109 442 lignes traitées avec Spark
- 0 NaN dans le dataset final
- 11 visualisations produites
- Modèle MLlib ($R^2 = 0.19$)
- Recommandations stocks, promos, prix